

# Test niezależności $\chi^2$

Maciej Beręsewicz

## 1 Test niezależności $\chi^2$

Punktem wyjścia w teście niezależności  $\chi^2$  jest dwuwymiarowa tablica kontyngencji  $\mathbf{N} = [n_{ij}]$ , gdzie  $n_{ij}$  oznaczają liczebności empiryczne w  $i$ -tym wierszu oraz  $j$ -tej kolumnie ( $i = 1, \dots, I$ ,  $j = 1, \dots, J$ ).

Tabela 1: Tablica kontyngencji dla dwóch zmiennych X i Y

Kategorie zmiennej X	Kategorie zmiennej Y				Suma wierszy
	$Y_1$	$Y_2$	$\dots$	$Y_J$	
$X_1$	$n_{11}$	$n_{12}$	$\dots$	$n_{1J}$	$n_{1.}$
$X_2$	$n_{21}$	$n_{22}$	$\dots$	$n_{2J}$	$n_{2.}$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
$X_I$	$n_{I1}$	$n_{I2}$	$\dots$	$n_{IJ}$	$n_{I.}$
<b>Suma kolumn</b>	$n_{.1}$	$n_{.2}$	$\dots$	$n_{.J}$	$n$

Źródło: Opracowanie własne.

Powyższa tabela przedstawia tablicę kontyngencji dla dwóch zmiennych X i Y, z których pierwsza ma  $I$ , a druga  $J$  wariantów.

W praktyce najczęściej wykorzystywanym narzędziem pozwalającym wykryć zależność między zmiennymi  $X$  i  $Y$  jest test  $\chi^2$  niezależności. *Hipoteza zerowa* –  $H_0$  zakłada brak związku między zmiennymi, czyli zmienne  $X$  i  $Y$  są niezależne, wobec *hipotezy alternatywnej* –  $H_1$ , że zmienne  $X$  i  $Y$  nie są niezależne. Sprawdzianem hipotezy zerowej jest statystyka:

$$\chi^2 = \sum_{i=1}^I \sum_{j=1}^J \frac{(n_{ij} - \hat{n}_{ij})^2}{\hat{n}_{ij}} \quad (1)$$

gdzie  $n_{ij}$  oraz  $\hat{n}_{ij}$  oznaczają odpowiednio empiryczne i teoretyczne liczebności tabeli kontyngencji. Liczebności teoretyczne  $\hat{n}_{ij}$  wyznaczamy ze wzoru:

$$\hat{n}_{ij} = \frac{n_{i.} n_{.j}}{n} \quad (2)$$

gdzie  $n$  oznacza liczebność próby, a  $n_{i.}$ ,  $n_{.j}$  liczebności brzegowe. Statystyka (1) przy założeniu prawdziwości hipotezy  $H_0$  ma graniczny rozkład  $\chi^2$  z  $(I-1)(J-1)$  stopniami swobody. Obszar krytyczny w teście  $\chi^2$  niezależności buduje się prawostronnie:

$$P(\chi^2 \geq \chi_\alpha^2) = \alpha \quad (3)$$

W przypadku tabeli 2x2

Tabela 2: Tabela 2x2

Cecha X	Cecha Y		Razem
	$Y_1$	$Y_2$	
$X_1$	A	B	A+B
$X_2$	C	D	C+D
<b>Razem</b>	A+C	B+D	N=A+B+C+D

*Źródło:* Opracowanie własne.

można skorzystać z następującego wzoru:

$$\chi^2 = \frac{n * (ad - bc)^2}{(a + b)(c + d)(a + c)(b + d)} \quad (4)$$

## 2 Test niezależności $\chi^2$ w SAS

**Zadanie 1.** Stosując test niezależności  $\chi^2$  sprawdź czy pomiędzy wykształceniem, a tym czy w ciągu ostatnich 3 lat osoba brała udział w szkoleniach istnieje zależność. Na podstawie 141 losowo zapytanych pracowników pewnej firmy uzyskano następujące wyniki. Przyjmij poziom istotności  $\alpha = 0,05$ .

Tabela 3: Tabla kontyngencji zadania 1

Wykształcenie	Udział w szkoleniach	Brak udziału w szkoleniach
Zawodowe	18	17
Średnie	34	19
Wyższe	38	15

Wczytanie danych

```
data zad1;
input  wykst $ szkolenie $ n;
datalines;
zawodowe tak 18
zawodowe nie 17
średnie tak 34
średnie nie 19
wyższe tak 38
wyższe nie 15
;
run;
```

Aby rozwiązać zadanie można wykorzystać do tego procedurę **PROC FREQ**. Kod znajduje się poniżej.

```
proc freq data=zad1;
table wykst*szkolenie /chisq;
weight n;
run;
```

Na podstawie poniższej tabeli należy stwierdzić, że nie mamy podstaw do odrzucenia  $H_0$  ponieważ  $p$ -value ( $prob$ ) jest większe od założonego poziomu istotności  $\alpha = 0,05$ . W związku z tym nie ma zależności między wykształceniem a udziałem w szkoleniach.

Statistic	DF	Value	Prob
Chi-Square	2	3.7550	0.1530
Likelihood Ratio Chi-Square	2	3.7240	0.1554
Mantel-Haenszel Chi-Square	1	0.6492	0.4204
Phi Coefficient		0.1632	
Contingency Coefficient		0.1611	
Cramer's V		0.1632	